

Scalabilità e Resilienza in Kubernetes: come le app Cloud-Native si auto-adattano al carico e rinascono dalle ceneri

...

Linux Day 2024
Francavilla Fontana



ing. Alessandro Argentieri

Mi presento



Ingegnere dell'Informazione presso il PoliBA

Lavoro da 10 anni in ambito IT

Appassionato in Architettura del Software e sistemi complessi

Tech-Lead @ Civo (civo.com), un Cloud Provider UK



[linkedin.com/in/alessandroargentieri](https://www.linkedin.com/in/alessandroargentieri)



alessandro@civo.com



github.com/alessandroargentieri

Indice

- piccola intro su Kubernetes (per chi è digiuno)
- i meccanismi di auto-adattamento di Kubernetes
- demo pratica



Kubernetes (k8s) spiegato a mia nonna



- è un progetto Open Source nato da Google
- donato alla CNCF (costola della Linux Foundation)
- è considerato il “Sistema Operativo” per il Cloud (CNCF annual survey 2022)
- **è un software distribuito che permette la gestione ed il rilascio centralizzato di app containerizzate su più macchine connesse**
- implementa una serie di pattern tipici per le app Cloud Native (load balancing, service-discovery, api-gateway, circuit-breaker, health-check, ...)
- curiosità: OpenAI usa un K8s di 7500 nodi



foto: **Kelsey Hightower**
pioniere dello sviluppo di
Kubernetes in Google

App containerizzate ?!?

App avviate come processi isolati (linux) chiamati **container** .

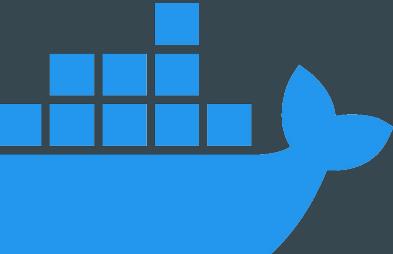
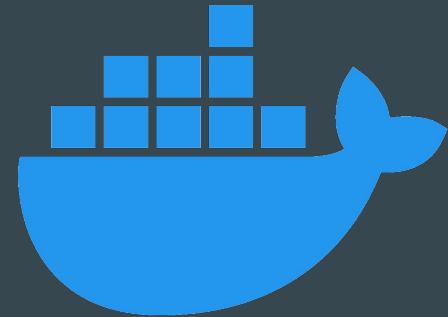
Simili a macchine virtuali ma più leggeri

I container condividono il sistema operativo linux (le chiamate al kernel)

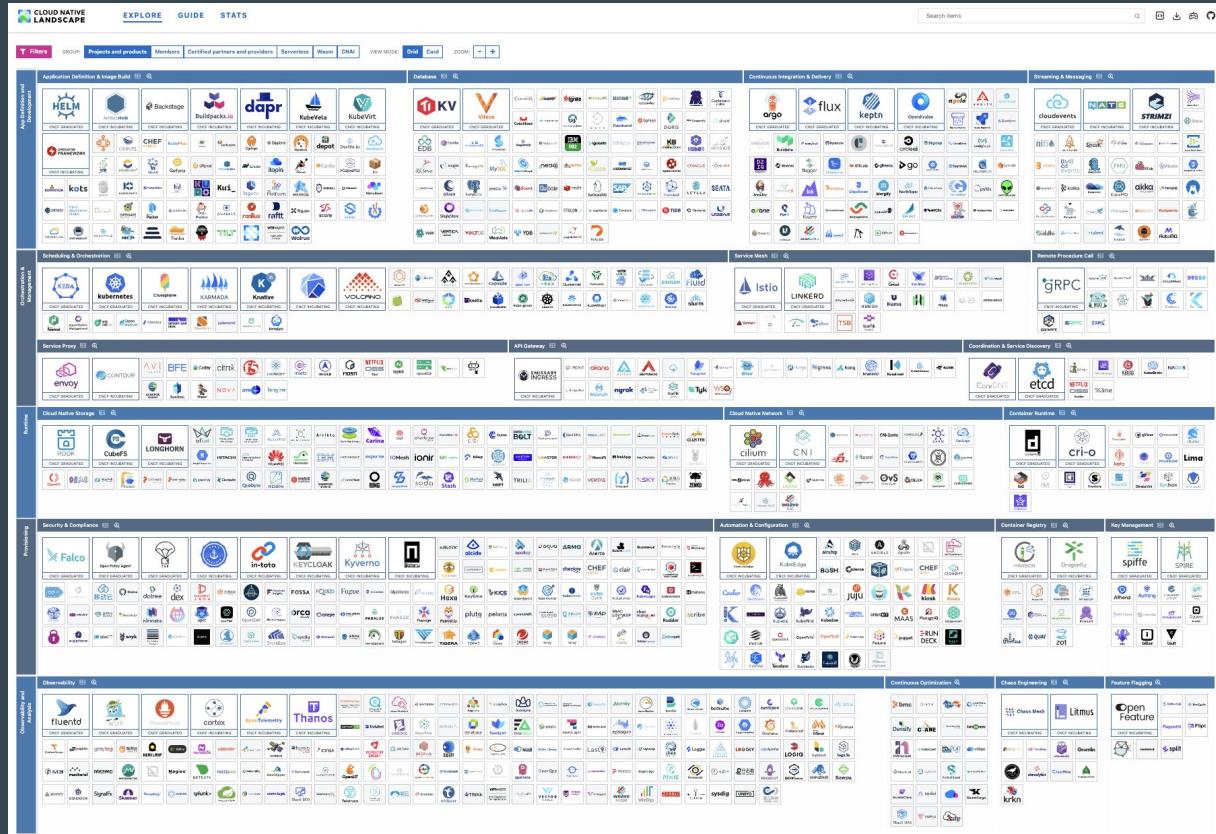
I processi nei container credono di avere una macchina propria (CPU/RAM/disco)

Come si avvia una macchina virtuale da una ISO, un container parte da un'**immagine**

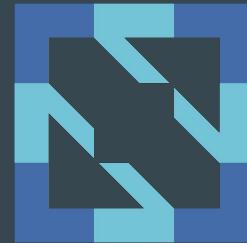
Le immagini sono salvate in **container registry** (es. Docker Hub)



CNCF: Cloud Native Computing Foundation



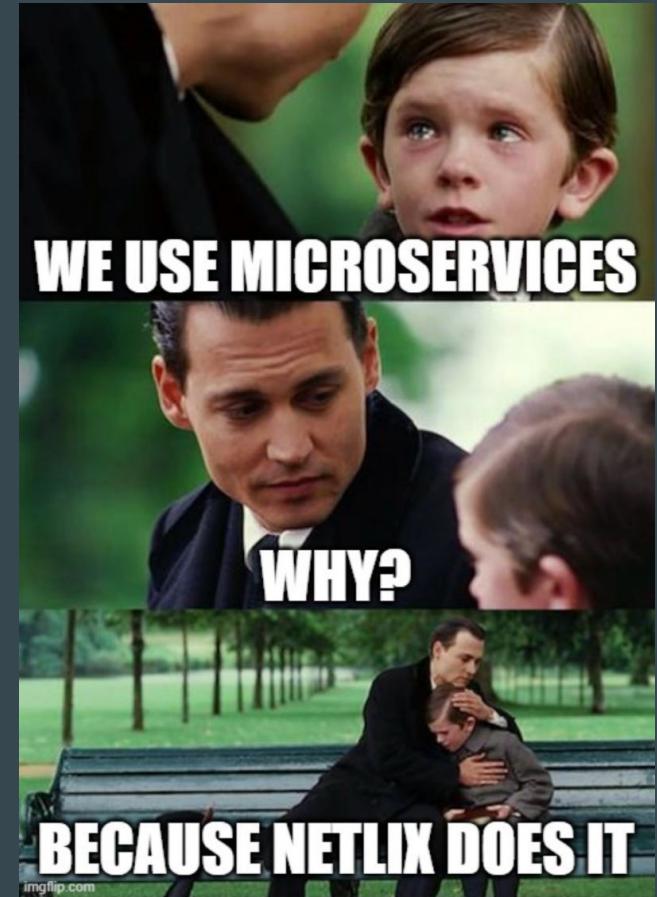
landscape.cncf.io



CLOUD NATIVE COMPUTING FOUNDATION

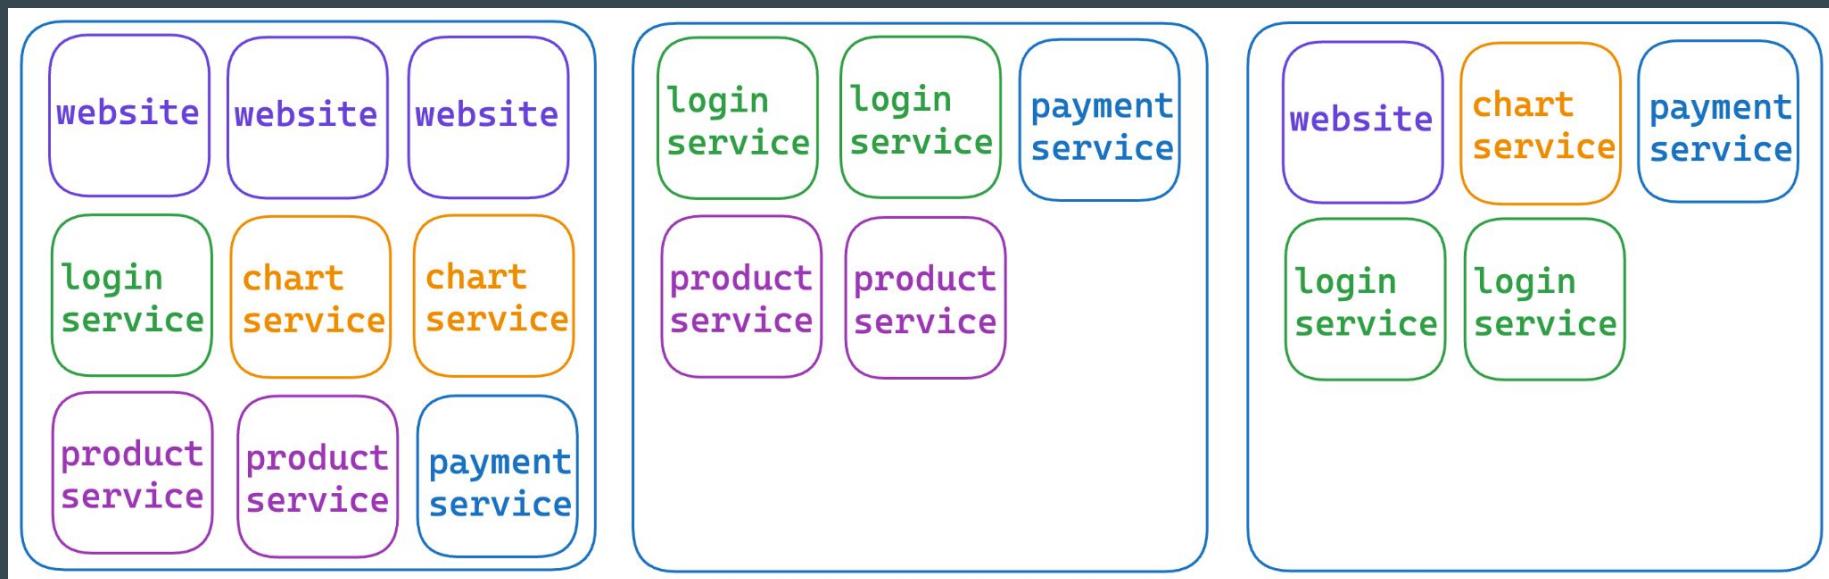
Le basi di Kubernetes

Immaginiamo un e-commerce composto da 5 microservizi che interagiscono tra loro



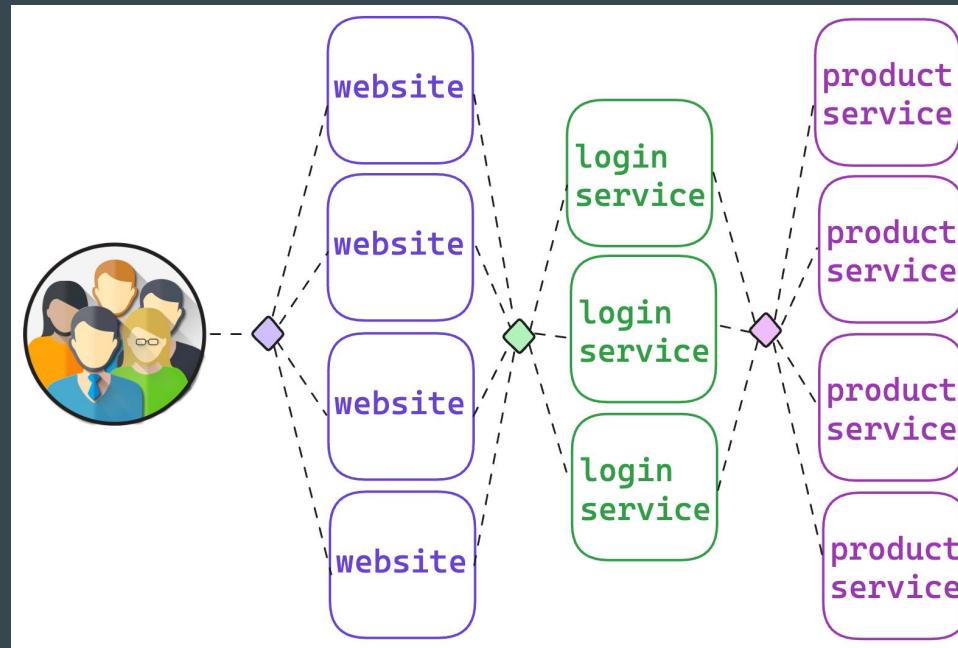
Le basi di Kubernetes

Il “cervello” del “cluster” Kubernetes distribuisce le app containerizzate nei vari nodi (macchine) disponibili con le repliche necessarie.



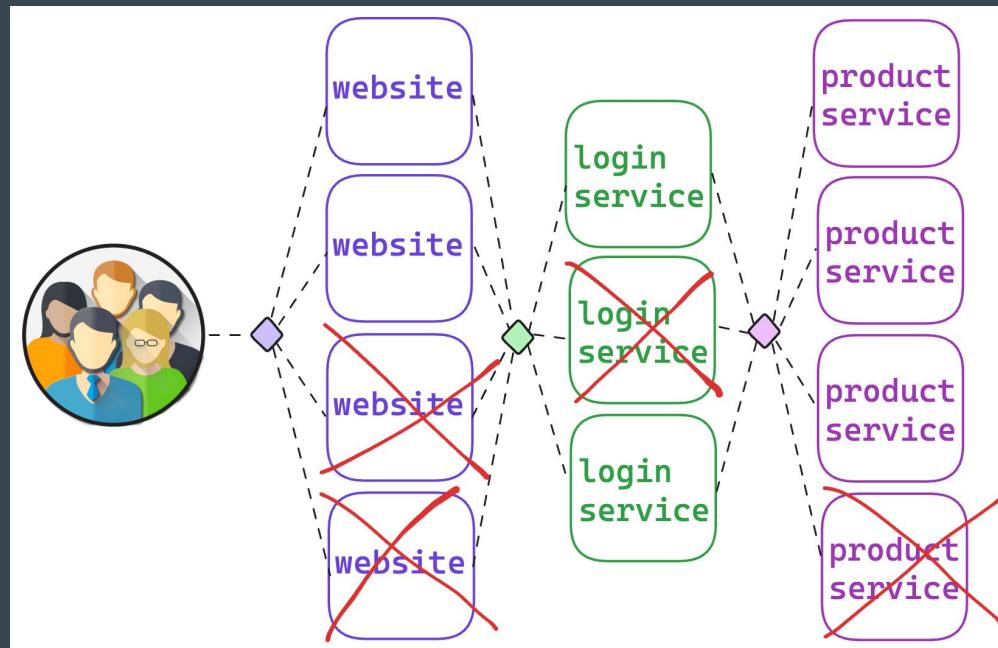
Le basi di Kubernetes

Gli utenti vedono l'app come un'entità unica, non curandosi di quanti servizi e quante repliche per servizio la costituiscono, né di quale macchina ospita quale replica



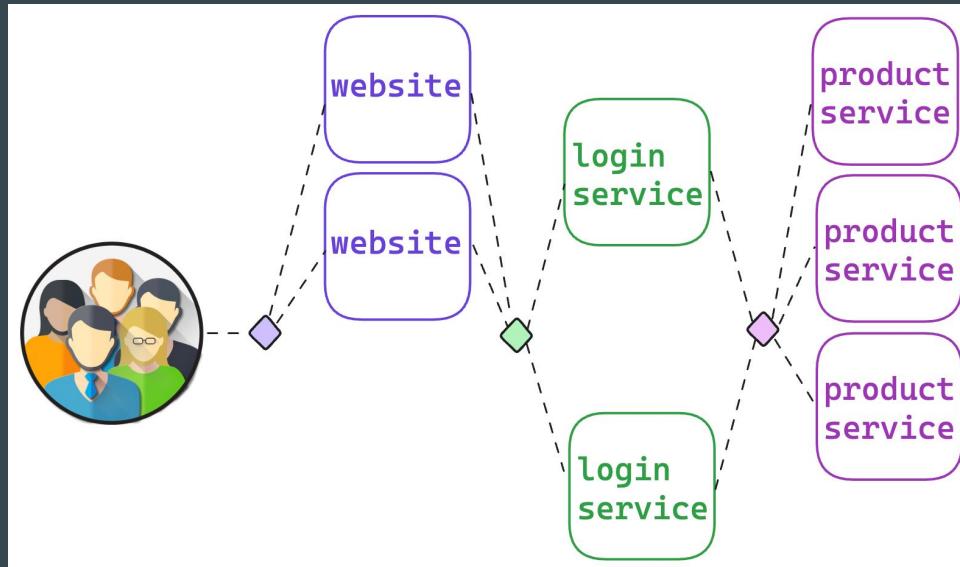
Le basi di Kubernetes

Se alcune repliche diventano irraggiungibili (crash del processo, problemi di rete, sovraccarico)



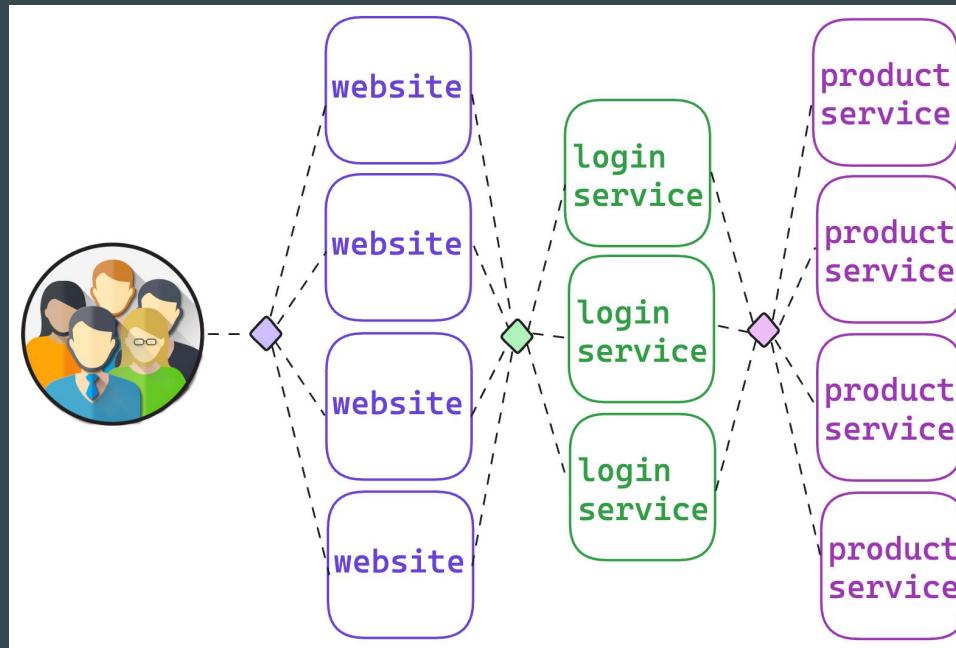
Le basi di Kubernetes

Kubernetes stacca i ponti per evitare che queste repliche siano utilizzate (produendo un errore ed interrompendo l'esperienza utente)



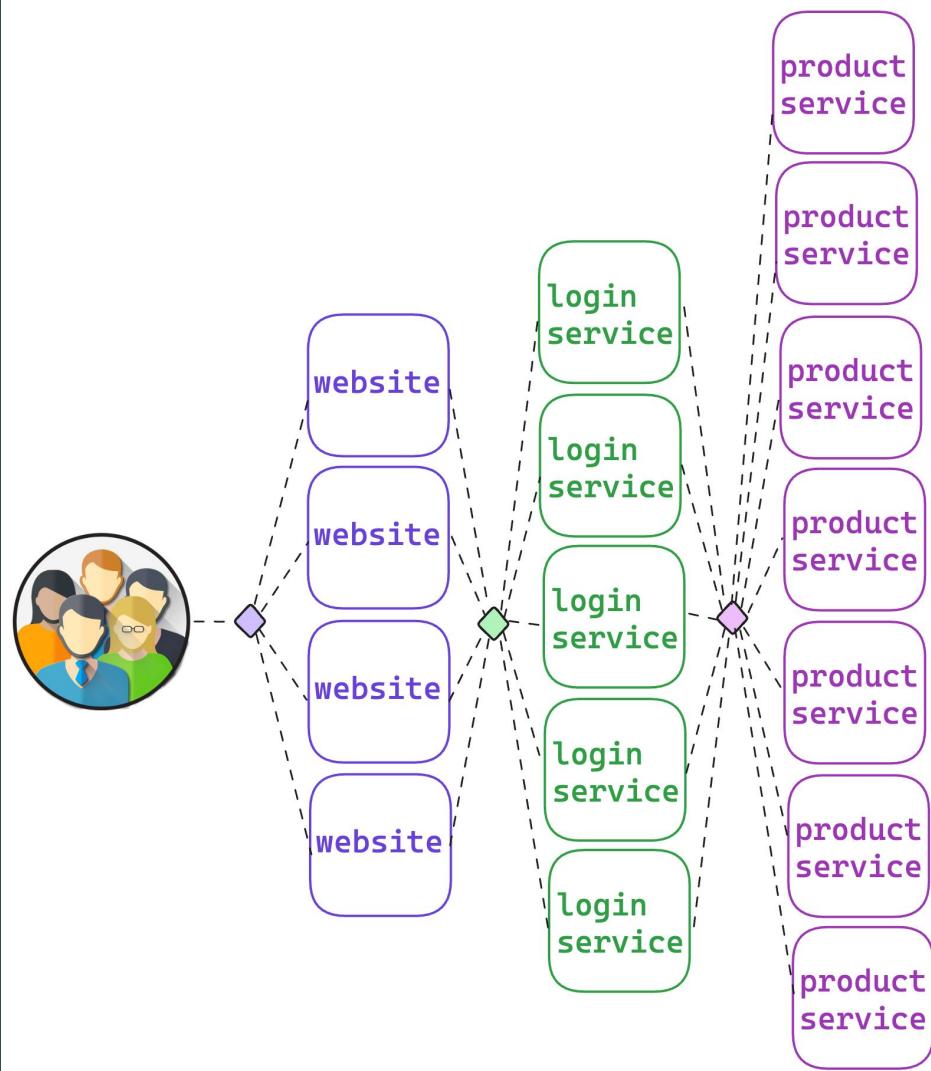
Le basi di Kubernetes

... e poco dopo la situazione viene ristabilita in automatico affinché lo stato reale raggiunga quello desiderato (programmazione dichiarativa - non imperativa)

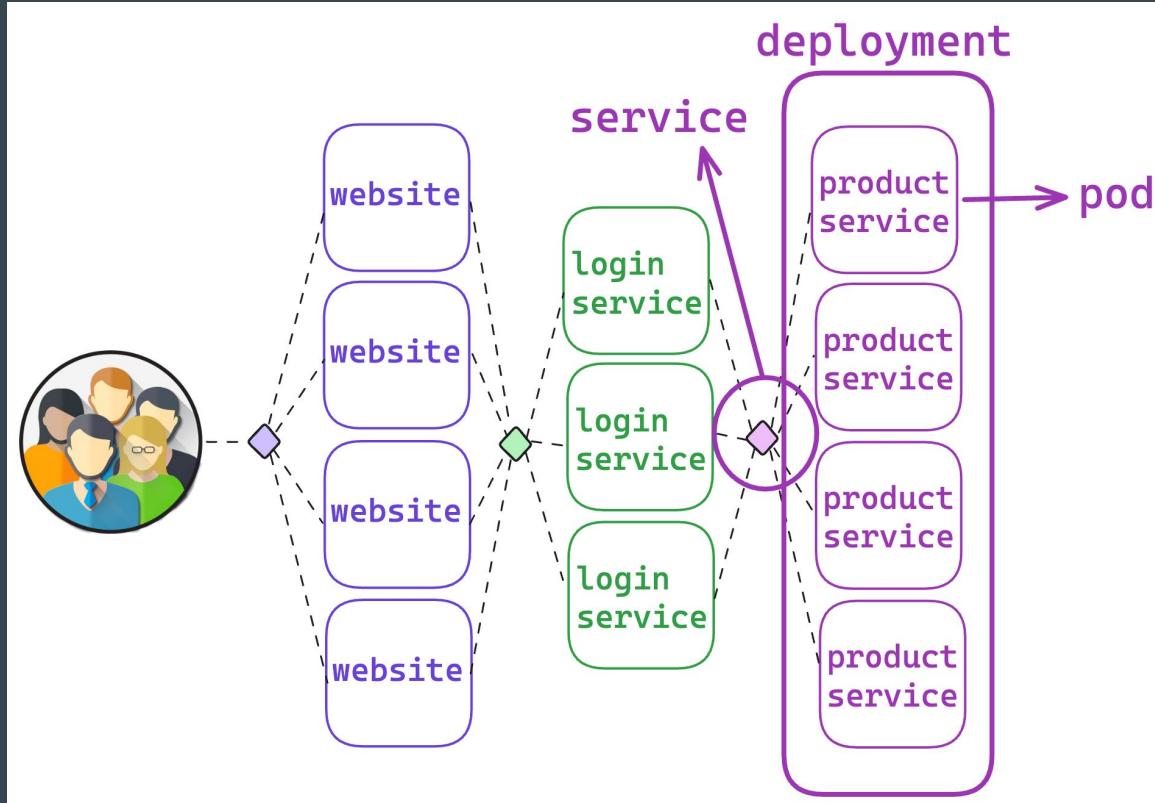


Le basi di Kubernetes

Se il traffico di rete aumenta e sono necessarie più repliche, il sistema reagisce e ne crea di nuove, adattandosi alle nuove necessità

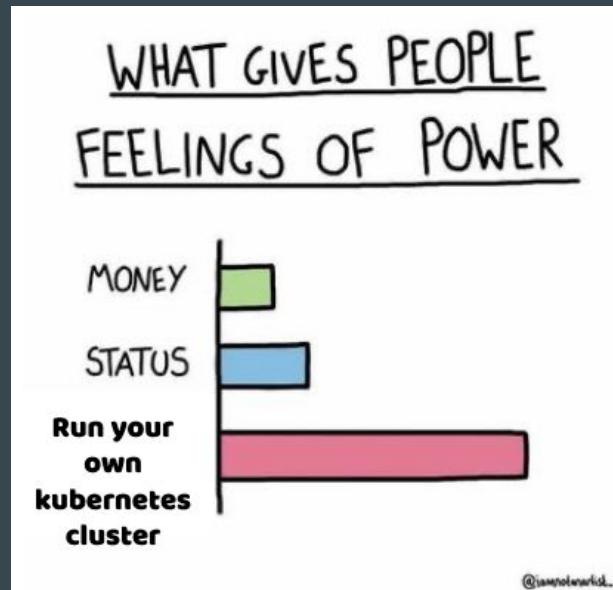


Le basi di Kubernetes

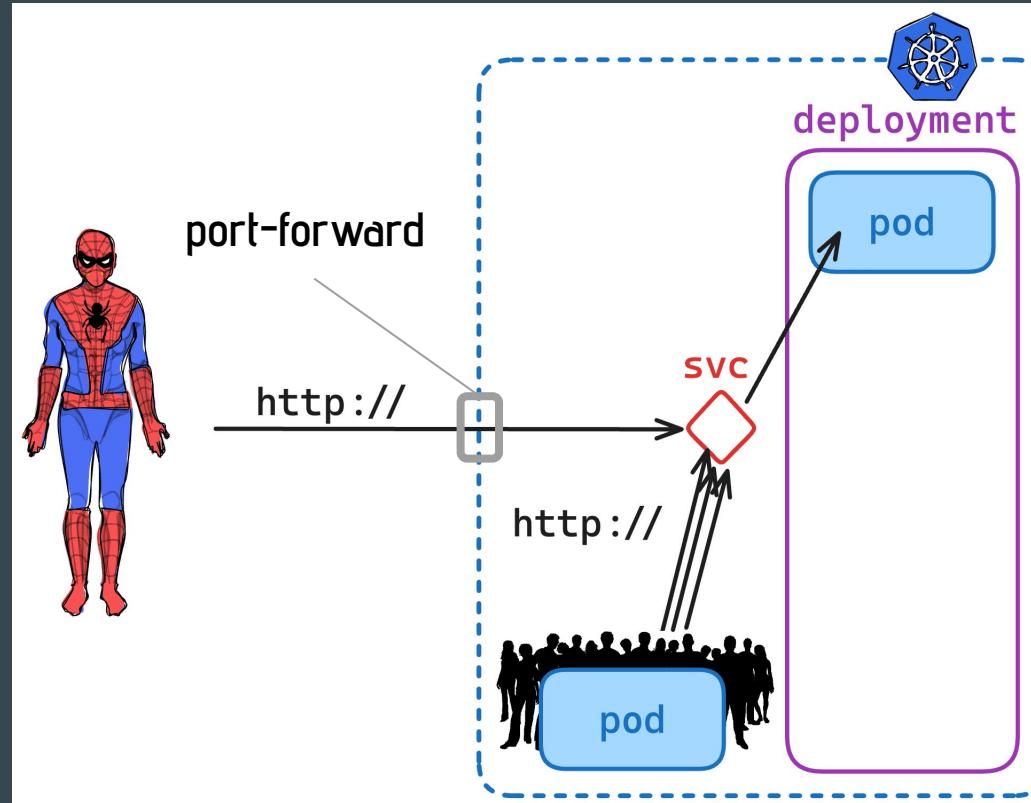


Piccola demo

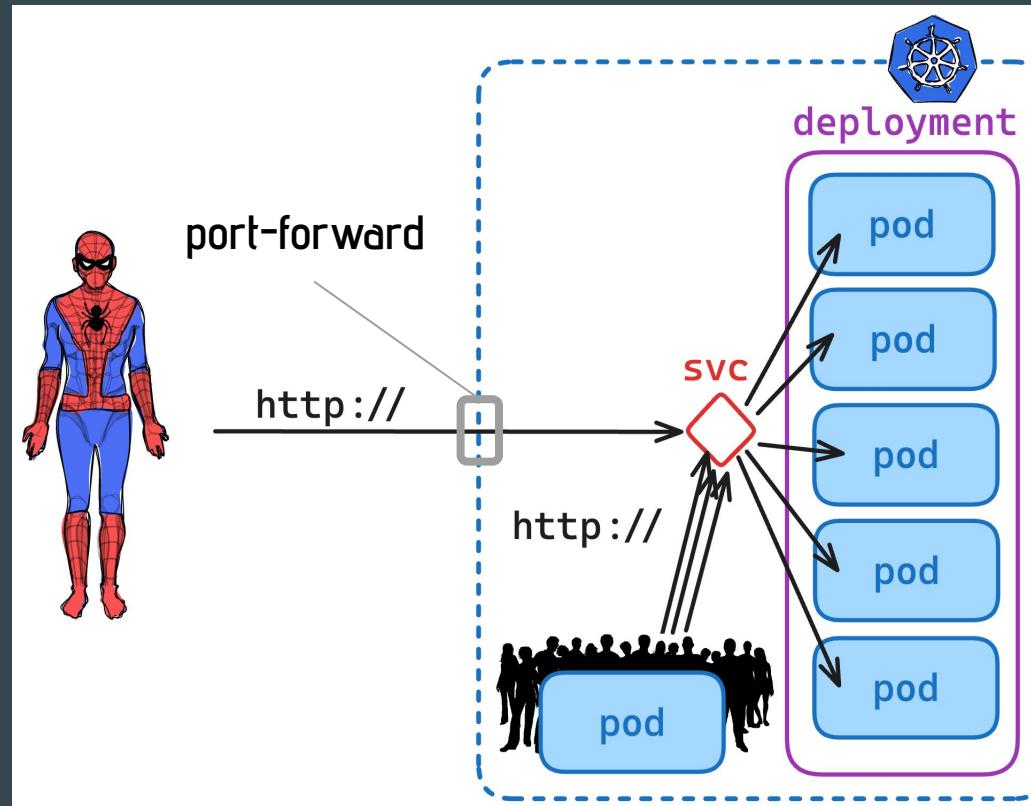
<https://github.com/f4rezer0/linux-day-2024-k8s-autoscaling>



Piccola demo



Piccola demo



Prerequisiti

Software installati sulla tua macchina:

- curl
- git
- docker
- kubectl



Prepariamo un cluster locale con k3d (k3s in docker)

• • •

install k3d

```
~ $ curl -s https://raw.githubusercontent.com/k3d-io/k3d/main/install.sh | bash
```

• • •

install k3d

```
~ $ k3d cluster create linuxday-k3d \
    --agents 2 \
    --port '80:80@loadbalancer' \
    --port '443:443@loadbalancer'
```

Installiamo i componenti nel cluster

● ● ●

install k3d

```
~ $ git clone https://github.com/f4rezer0/linux-day-2024-k8s-autoscaling.git  
~ $ cd linux-day-2024-k8s-autoscaling
```

● ● ●

install k3d

```
~/linux-day-2024-k8s-autoscaling (main) $ kubectl apply -f metrics-server.yaml  
~/linux-day-2024-k8s-autoscaling (main) $ kubectl apply -f php-apache.yaml
```

```
deployment.apps/php-apache-deployment created  
horizontalpodautoscaler.autoscaling/php-apache-hpa created  
service/php-apache-svc created
```

Installiamo i componenti nel cluster

...

list of the services

```
$ kubectl get services
```

NAME	TYPE	CLUSTER-IP	EXTERNAL-IP	PORT(S)	AGE
kubernetes	ClusterIP	10.43.0.1	<none>	443/TCP	4h42m
php-apache-svc	LoadBalancer	10.43.218.244	<pending>	80:31319/TCP	4h38m

...

list of the deployments

```
$ kubectl get deployments
```

NAME	READY	UP-TO-DATE	AVAILABLE	AGE
php-apache-deployment	1/1	1	1	4h35m



...

list of the pods

```
$ kubectl get pods
```

NAME	READY	STATUS	RESTARTS	AGE
php-apache-deployment-5bdbb8dbf8-wrtxl	1/1	Running	0	4h10m

Test del deployment

● ● ●

port-forward the service on localhost:8888

```
$ kubectl port-forward svc/php-apache-svc 8888:80
Forwarding from 127.0.0.1:8888 -> 80
Forwarding from [::1]:8888 -> 80
```

● ● ●

port-forwarding

```
~ $ curl http://localhost:8888
OK!
```

Simuliamo il carico



create a load-generator pod

```
$ kubectl run -i --tty load-generator --rm --image=busybox:1.28 --restart=Never -- /bin/sh -c  
"while sleep 0.01; do wget -q -O- http://php-apache-svc; done"
```



list the pods

```
$ kubectl get pods
```

NAME	READY	STATUS	RESTARTS	AGE
php-apache-deployment-5bdbb8dbf8-wrtxl	1/1	Running	0	4h46m
load-generator	1/1	Running	0	3m26s
php-apache-deployment-5bdbb8dbf8-s2nj4	1/1	Running	0	3m6s
php-apache-deployment-5bdbb8dbf8-n5n4v	1/1	Running	0	3m6s
php-apache-deployment-5bdbb8dbf8-vpvzc	1/1	Running	0	3m6s
php-apache-deployment-5bdbb8dbf8-nj4nc	1/1	Running	0	2m21s
php-apache-deployment-5bdbb8dbf8-fpcgt	1/1	Running	0	2m21s

Approfondimento: ispezioniamo k3d con Docker (1)



inspect the kubernetes node

```
$ kubectl get nodes
NAME                  STATUS   ROLES          VERSION
k3d-linuxday-k3d-server-0   Ready    control-plane, master   v1.27.4+k3s1
k3d-linuxday-k3d-agent-1    Ready    <none>        v1.27.4+k3s1
k3d-linuxday-k3d-agent-0    Ready    <none>        v1.27.4+k3s1
```



inspect the pods

```
$ kubectl get pods
NAME                  READY   STATUS
php-apache-deployment-5bdbb8dbf8-28ld9   1/1     Running
```

Approfondimento: ispezioniamo k3d con Docker (1)

• • •

inspect the kubernetes node

```
$ docker ps | grep k3s1
6d921f65e059  rancher/k3s:v1.27.4-k3s1  k3d-linuxday-k3d-agent-1
aead2f2e57a1  rancher/k3s:v1.27.4-k3s1  k3d-linuxday-k3d-agent-0
1e7c713453b6  rancher/k3s:v1.27.4-k3s1  k3d-linuxday-k3d-server-0
```

• • •

inspect the pods

```
$ docker exec k3d-lxd1-k3d-agent-0 crictl ps | grep php
CONTAINER          STATE           NAME            POD
5f70e8fdab916    Running        php-apache      php-apache-deployment-5bdbb8dbf8-28ld9
```

Grazie dell'attenzione



farezero.org



[linkedin.com/in/alessandroargentieri](https://www.linkedin.com/in/alessandroargentieri)



github.com/alessandroargentieri



alessandro@civo.com

